

# 编程实训作业

陆博福

2025 年 9 月

## 1 查漏补缺

以下是一些在课堂学习过程中提及的、较为陌生或不熟悉的词汇，在进一步查阅资料学习后记录了笔记。

### 1.1 最小点覆盖与最大边匹配

边匹配是一个边集合  $M \subseteq E$ ，其中任意两条边不共享同一个顶点。即：对于任意  $e_1, e_2 \in M$ ， $e_1 \neq e_2$ ，且  $e_1$  和  $e_2$  没有公共顶点。

点覆盖是一个顶点集合  $C \subseteq V$ ，使得每一条边  $(u, v) \in E$  至少有一个端点属于  $C$ 。即：对任意边  $(u, v) \in E$ ，有  $u \in C$  或  $v \in C$ 。

在一个二分图中，最大匹配的大小等于最小点覆盖的大小。假设图  $G = (V, E)$  是一个二分图，其中  $M$  是一个边匹配， $C$  是一个点覆盖。

则：最大匹配的大小为  $|M_{\max}|$ ，最小点覆盖的大小为  $|C_{\min}|$

根据 König 定理：

$$|M_{\max}| = |C_{\min}|$$

应用场景：任务分配、网络流中的最大流与最小割、计算机视觉中的图像分割、电路布线与逻辑门设计、生物信息学中的基因调控网络、社交网络中的影响力传播、在线广告投放策略等。

## 1.2 匈牙利算法

匈牙利算法 (Hungarian Algorithm) 是一种用于解决分配问题 (Assignment Problem) 的算法。它主要用于在一个成本矩阵中找到一种最优的分配方式, 使得总成本最小 (或最大)。例如, 在一个任务分配问题中, 每个工人只能分配一个任务, 每个任务也只能由一个工人完成, 而目标是使总成本最低。

算法的核心是通过一系列操作来寻找**最小权完美匹配**, 其步骤大致如下:

**构造代价矩阵:** 将问题转化为一个矩阵, 其中元素表示某人做某事的成本或时间。

**行减法和列减法:** 对每一行和每一列减去该行或该列的最小值, 使得至少有一行或一列出现 0。

**尝试覆盖所有 0:** 用最少的直线覆盖所有 0, 判断是否可以找到一个完美匹配。

**调整矩阵:** 如果不能找到完美匹配, 则调整矩阵, 重复上述过程, 直到找到一个完美匹配为止。

Listing 1: 匈牙利算法伪代码

```
1 for each row:
2     subtract min(row)
3 for each column:
4     subtract min(column)
5 while lines < n:
6     cover zeros with minimum lines
7     if lines < n:
8         find min uncovered, adjust matrix
9 find optimal assignment
```

### 1.3 阿列夫零

阿列夫零 (Aleph-null, 符号为  $\aleph_0$ ) 是数学中用来表示最小的无限基数的符号, 它代表的是可数无限集合的大小。例如, 自然数集合  $\{0, 1, 2, 3, \dots\}$  的基数就是阿列夫零。

在集合论中, 阿列夫零是第一个阿列夫数, 用于描述无限集合的“大小”。与之相对的是更大的无限基数, 如阿列夫一 ( $\aleph_1$ )、阿列夫二 ( $\aleph_2$ ) 等, 它们分别对应不可数无限集合的大小。

简单来说, 任何与自然数集合具有相同基数的无限集合都是可数无限的, 而像实数集合这样的无限集合则是不可数无限的, 其基数大于阿列夫零。

### 1.4 共轭先验

共轭先验 (Conjugate Prior) 是贝叶斯统计中的一个重要概念, 用于简化后验分布的计算。它的基本思想是: **选择一个与似然函数具有相同形式的先验分布**, 这样在计算后验分布时, 可以保持相同的分布形式, 从而避免复杂的积分运算。

如果一个先验分布  $p(\theta)$  与似然函数  $p(x|\theta)$  的乘积 (即联合分布) 在归一化之后, 仍然是一个已知的、容易处理的分布形式, 那么这个先验分布就被称为**共轭先验**。

换句话说, 若:

$$p(\theta|x) \propto p(x|\theta) \cdot p(\theta)$$

且  $p(\theta|x)$  是某种已知分布 (如正态分布、贝塔分布等), 那么  $p(\theta)$  就是  $p(x|\theta)$  的共轭先验。

**计算简便** 共轭先验与似然函数属于同一概率分布族, 因此后验分布的形式与先验分布相同。这使得后验分布的计算变得简单, 无需复杂的数值积分或近似方法。

**易于更新** 当获得新的数据时, 只需对先验参数进行更新, 而不需要重新计算整个后验分布。这种特性使得共轭先验非常适合在线学习和动态模型更新。

**适合解析求解** 在许多情况下, 共轭先验允许直接解析地得到后验分布, 而不是依赖于蒙特卡洛模拟或其他数值方法。

似然函数	共轭先验	后验分布
$\mathcal{N}(\mu)$	$\mathcal{N}(\mu_0, \sigma_0^2)$	$\mathcal{N}(\mu_n, \sigma_n^2)$
$\mathcal{N}(\sigma^2)$	Inv-Gamma( $\alpha_0, \beta_0$ )	Inv-Gamma( $\alpha_n, \beta_n$ )
Bernoulli( $p$ )	Beta( $\alpha_0, \beta_0$ )	Beta( $\alpha_n, \beta_n$ )
Binomial( $p$ )	Beta( $\alpha_0, \beta_0$ )	Beta( $\alpha_n, \beta_n$ )
Poisson( $\lambda$ )	Gamma( $\alpha_0, \beta_0$ )	Gamma( $\alpha_n, \beta_n$ )
Gamma( $\alpha$ )	Inv-Gamma( $\alpha_0, \beta_0$ )	Inv-Gamma( $\alpha_n, \beta_n$ )

表 1: 常见分布及其共轭先验与后验分布

## 2 二项分布与泊松二项复合分布的比较分析

现有两种模型，一是二项分布，固定投 100 次硬币，三次实验正面朝上的次数分别为 49、50、51 次，二是先泊松分布再二项分布，投硬币固定计时 2 分钟，平均投 100 次，实验得到的正面朝上次数也是 49、50、51。下面比较两种模型的差异：

### 2.1 两种模型设定及其期望与方差

#### 2.1.1 单独二项分布

$X \sim B(n, p)$   $X$  表示在  $n$  次独立重复试验中成功次数，每次成功的概率为  $p$ 。

- 期望：  $E(X) = np$
- 方差：  $Var(X) = np(1 - p)$

#### 2.1.2 先泊松后二项

$X \sim B(N, p), N \sim Poisson(\lambda)$  设  $N$  表示在可能进行试验的次数， $X$  表示  $N$  次试验成功的次数，每次成功的概率为  $p$

- 边缘期望：

$$E(X) = E(E(X|N)) = E(Np) = pE(N) = \lambda p$$

即  $E(X) = \lambda p$

- 边缘方差：

$$Var(X) = E(Var(X|N)) + Var(E(X|N))$$

其中：  $E(Var(X|N)) = E(Np(1 - p)) = p(1 - p)E(N) = p(1 - p)\lambda$   $Var(E(X|N)) = Var(Np) = p^2 Var(N) = p^2 \lambda$

因此：

$$Var(X) = p(1 - p)\lambda + p^2 \lambda = \lambda p$$

即

表 2: 两种模型设定及其期望与方差

模型设定	分布	期望 $E(X)$	方差 $Var(X)$
单独二项分布	$X \sim B(n, p)$	$np$	$np(1 - p)$
先泊松后二项	$X   N \sim B(N, p), N \sim Poisson(\lambda)$	$\lambda p$	$\lambda p$

## 2.2 矩估计

矩估计的核心思想：用样本的矩（如均值、方差等）去估计总体的矩。

### 2.2.1 二项分布

总体期望（一阶矩）： $E(X_1) = np_1$

总体方差（二阶矩）： $\text{Var}(X_1) = np_1(1 - p_1)$

计算样本均值

$$\bar{X}_1 = \frac{1}{n} \sum_{i=1}^n X_1 i$$

用样本均值估计总体均值

$$E(X_1) = np_1 = \bar{X}_1$$

解得：

$$\hat{p}_1 = \frac{\bar{X}_1}{n}$$

### 2.2.2 先泊松再二项

计算样本均值

$$E(X_2) = \sum_{n=0}^{\infty} \sum_{x=0}^n x \cdot f_{X_2|N_2}(x|n) \cdot f_{N_2}(n)$$

其中：

$$f_{X_2|N_2}(x|n) = \binom{n}{x} p_2^x (1 - p_2)^{n-x} \quad (x \leq n)$$

$$f_{N_2}(n) = \frac{\lambda^n e^{-\lambda}}{n!}$$

因此：

$$\begin{aligned} E(X_2) &= \sum_{n=0}^{\infty} E(X_2 | N_2 = n) \cdot f_{N_2}(n) = \sum_{n=0}^{\infty} np_2 \cdot f_{N_2}(n) \\ &= p_2 \sum_{n=0}^{\infty} n f_{N_2}(n) = p_2 \cdot E(N_2) \end{aligned}$$

因为  $N_2 \sim \text{Poisson}(\lambda)$ ，所以：

$$E(N_2) = \lambda$$

因此：

$$E(X_2) = p_2 \cdot \lambda$$

用样本均值估计总体均值

$$\bar{X}_2 = p_2 \cdot \lambda$$

解得：

$$\hat{p}_2 = \frac{\bar{X}_2}{\lambda}$$

## 2.3 矩估计的无偏性与有效性

### 2.3.1 单独二项分布

无偏性

$$E[\hat{p}_1] = E\left[\frac{x_1}{n}\right] = \frac{1}{n}E[x_1] = \frac{1}{n}(np_1) = p_1$$

——无偏（期望等于自身）

有效性

$$\text{Var}(\hat{p}_1) = \text{Var}\left(\frac{x_1}{n}\right) = \frac{1}{n^2} \cdot \text{Var}(x_1)$$

由于  $\text{Var}(X_1) = np_1(1 - p_1)$  因此：

$$\text{Var}(\hat{p}_1) = \frac{p_1(1 - p_1)}{n}$$

Fisher 信息量：

$$I(p_1) = \frac{n}{p_1(1 - p_1)}$$

Cramér-Rao 下界：

$$\frac{1}{nI(p_1)} = \frac{p_1(1 - p_1)}{n}$$

——有效（在 Cramér-Rao 下界下）

### 2.3.2 先泊松再二项

无偏性

$$E[\hat{p}_2] = E\left[\frac{x_2}{\lambda}\right] = \frac{1}{\lambda}E[x_2] = \frac{1}{\lambda}(p_2\lambda) = p_2$$

——无偏（期望等于自身）

**有效性**

$$\text{Var}(\hat{p}_2) = \frac{1}{\lambda^2} \cdot \text{Var}(x_2)$$

因为  $\text{Var}(x_2) = p_2\lambda$ , 所以:

$$\text{Var}(\hat{p}_2) = \frac{p_2\lambda}{\lambda^2} = \frac{p_2}{\lambda}$$

方差比直接对二项分布估计要大  $\frac{n}{(1-p)\lambda}$  倍 (若假设  $\lambda = n$  则为  $\frac{1}{1-p}$ ), 但仍是有效的

## 2.4 最大似然估计

最大似然估计的核心思想: 找到一组参数值, 使得在这组参数下, 观测到当前数据的概率 (即似然函数) 最大。

**数学表达** 假设我们有一组独立同分布 (i.i.d.) 的观测数据  $x_1, x_2, \dots, x_n$ , 这些数据来自一个概率分布, 该分布的概率密度函数 (PDF) 或概率质量函数 (PMF) 为  $f(x | \theta)$ , 其中  $\theta$  是我们要估计的未知参数。

似然函数定义为:

$$L(\theta) = \prod_{i=1}^n f(x_i | \theta)$$

为了方便计算, 通常取对数似然函数:

$$\ell(\theta) = \log L(\theta) = \sum_{i=1}^n \log f(x_i | \theta)$$

最大似然估计的目标是找到使对数似然函数最大的参数值  $\hat{\theta}$ :

$$\hat{\theta}_{\text{MLE}} = \arg \max_{\theta} \ell(\theta)$$

### 2.4.1 二项分布

**概率质量函数**

$$P(X_1 = x) = \binom{n}{x} p_1^x (1 - p_1)^{n-x}, \quad x = 0, 1, \dots, n$$

**对数似然函数** 假设观测数据为  $x_1$ , 则似然函数为:

$$L(p_1) = \binom{n}{x_1} p_1^{x_1} (1 - p_1)^{n-x_1}$$

对数似然函数:

$$\ell(p_1) = \log L(p_1) = \log \binom{n}{x_1} + x_1 \log p_1 + (n - x_1) \log(1 - p_1)$$

最大化对数似然函数 对  $p_1$  求导并令其为零：

$$\frac{d\ell}{dp_1} = \frac{x_1}{p_1} - \frac{n - x_1}{1 - p_1} = 0$$

解得：

$$\frac{x_1}{p_1} = \frac{n - x_1}{1 - p_1} \Rightarrow x_1(1 - p_1) = p_1(n - x_1)$$

$$x_1 - x_1 p_1 = n p_1 - x_1 p_1 \Rightarrow x_1 = n p_1 \Rightarrow p_1 = \frac{x_1}{n}$$

最大似然估计量为：

$$\hat{p}_1 = \frac{x_1}{n}$$

#### 2.4.2 先泊松再二项

##### 联合分布与边缘分布

- 联合分布

$$P(X_2 = x, N = n) = P(N = n) \cdot P(X_2 = x | N = n)$$

$$= e^{-\lambda} \frac{\lambda^n}{n!} \binom{n}{x} p_2^x (1 - p_2)^{n-x}$$

- 边缘分布

$$P(X_2 = x) = \sum_{n=x}^{\infty} e^{-\lambda} \frac{\lambda^n}{n!} \binom{n}{x} p_2^x (1 - p_2)^{n-x}$$

这个求和可以简化为：

$$\begin{aligned} P(X_2 = x) &= e^{-\lambda} \frac{(\lambda p_2)^x}{x!} \sum_{n=x}^{\infty} \frac{(\lambda(1 - p_2))^{n-x}}{(n - x)!} \\ &= e^{-\lambda} \frac{(\lambda p_2)^x}{x!} e^{\lambda(1 - p_2)} = \frac{(\lambda p_2)^x e^{-\lambda p_2}}{x!} \end{aligned}$$

也就是说，尽管我们从泊松分布再加一个二项分布，得到的边缘分布仍然是一个泊松分布



**似然函数** 设观测数据为  $x_2$ , 且  $X_2 \sim \text{Poisson}(\lambda p_2)$ , 那么:

$$P(X_2 = x_2) = \frac{(\lambda p_2)^{x_2} e^{-\lambda p_2}}{x_2!}$$

- 似然函数

$$L(p_2, \lambda) = \prod_{i=1}^n \frac{(\lambda p_2)^{x_i} e^{-\lambda p_2}}{x_i!}$$

- 对数似然函数

$$\ell(p_2, \lambda) = \sum_{i=1}^n [x_i \log(\lambda p_2) - \lambda p_2 - \log(x_i!)]$$

$$= \sum_{i=1}^n x_i \log(\lambda p_2) - n \lambda p_2 - \sum_{i=1}^n \log(x_i!)$$

**最大化对数似然** 将  $\lambda$  和  $p_2$  视为独立参数, 分别对它们求偏导。

- 对  $\lambda$  求偏导:

$$\frac{\partial \ell}{\partial \lambda} = \sum_{i=1}^n \frac{x_i}{\lambda p_2} - n p_2 = 0$$

$$\Rightarrow \frac{1}{\lambda p_2} \sum x_i = n p_2 \Rightarrow \frac{\bar{x}}{p_2} = n p_2 \Rightarrow \bar{x} = n p_2^2$$

- 对  $p_2$  求偏导:

$$\frac{\partial \ell}{\partial p_2} = \sum_{i=1}^n \frac{x_i}{p_2} - n \lambda = 0 \Rightarrow \frac{\bar{x}}{p_2} = n \lambda \Rightarrow \bar{x} = n \lambda p_2$$

- 联立两个方程:

$$\bar{x} = n p_2^2 \quad (\text{来自 } \partial/\partial \lambda)$$

$$\bar{x} = n \lambda p_2 \quad (\text{来自 } \partial/\partial p_2)$$

$$n \lambda p_2 = n p_2^2 \Rightarrow \lambda = p_2$$

最大似然估计量:

$$\hat{p}_2 = \sqrt{\frac{\bar{x}}{n}}, \quad \text{当 } \lambda = p_2$$

## 2.5 最大似然估计的无偏性与有效性

### 2.5.1 单独二项分布

$$\hat{p}_1 = \frac{x_1}{n}$$

无偏性

$$E\left[\frac{X_1}{n}\right] = \frac{1}{n}E[X_1] = \frac{1}{n}(np_1) = p_1$$

单独二项分布的最大似然估计是无偏的。

有效性

- 方差计算：

$$\text{Var}\left(\frac{X_1}{n}\right) = \frac{1}{n^2} \cdot \text{Var}(X_1) = \frac{1}{n^2} \cdot np_1(1-p_1) = \frac{p_1(1-p_1)}{n}$$

- Fisher 信息量：对于  $X \sim \text{Binomial}(n, p)$ ，Fisher 信息量为：

$$I(p) = \frac{n}{p(1-p)}$$

- Cramér-Rao 下界：

$$\frac{1}{nI(p)} = \frac{p(1-p)}{n}$$

与方差一致。达到 Cramér-Rao 下界，独立二项分布的最大似然估计是有效的估计量。

### 2.5.2 先泊松再二项

$$\hat{p}_2 = \sqrt{\frac{\bar{x}}{n}}, \quad \text{假设 } \lambda = p_2$$

无偏性

$$E[\hat{p}_2] = E\left[\sqrt{\frac{\bar{x}}{n}}\right]$$

由于  $\bar{x} \sim \text{Poisson}(\lambda p_2)$ ，且  $\hat{p}_2 = \sqrt{\frac{\bar{x}}{n}}$  是非线性变换，因此：

$$E[\hat{p}_2] \neq \sqrt{\frac{E[\bar{x}]}{n}} = \sqrt{\frac{\lambda p_2}{n}}$$

而真实值是  $p_2$ ，显然不等于上式。

结论：先泊松再二项的最大似然估计不是无偏的。

## 有效性

- Cramér-Rao 下界对于参数  $p_2$ , Fisher 信息量为:

$$I(p_2) = \frac{n}{p_2(1-p_2)}$$

- 实际方差

$$\hat{p}_2^{\text{MLE}} = \sqrt{\frac{\bar{x}}{n}}, \quad \bar{x} \sim \text{Poisson}(\lambda p_2)$$

用泰勒展开近似期望和方差:

$$E[\hat{p}_2^{\text{MLE}}] \approx \sqrt{\frac{\lambda p_2}{n}} + \frac{1}{2} \cdot \frac{1}{\sqrt{\frac{\lambda p_2}{n}}} \cdot \frac{\lambda p_2}{n} = \sqrt{\frac{\lambda p_2}{n}} + \frac{1}{2} \sqrt{\frac{\lambda p_2}{n}} = \frac{3}{2} \sqrt{\frac{\lambda p_2}{n}}$$

$$\text{Var}(\hat{p}_2^{\text{MLE}}) \approx \frac{1}{4} \cdot \frac{\text{Var}(\bar{x})}{E[\bar{x}]} = \frac{1}{4} \cdot \frac{\lambda p_2}{\lambda p_2/n} = \frac{n}{4}$$

这与期望不符,说明估计量的方差也偏离了理论下界。

先泊松再二项的最大似然估计在一般情况下不是有效的。

## 2.6 两种模型的差异比较

- 参数结构差异 (固定试验 vs 随机试验次数): 单独二项分布中, 试验次数  $n$  是固定的, 参数为成功概率  $p$ ; 而在“先泊松再二项”模型中, 试验次数  $N \sim \text{Poisson}(\lambda)$  是随机的, 因此需要同时估计两个参数  $p$  和  $\lambda$ 。
- 期望与方差形式差异 (如复合模型方差更大): 单独二项分布的期望为  $E[X] = np$ , 方差为  $\text{Var}(X) = np(1-p)$ ; 在“先泊松再二项”模型中, 边缘分布为  $X \sim \text{Poisson}(\lambda p)$ , 其期望为  $E[X] = \lambda p$ , 方差为  $\text{Var}(X) = \lambda p$ 。因此, 在相同期望下, 复合模型的方差通常更大。
- 应用场景差异 (稀有事件计数 vs 抽样调查): 单独二项分布适用于抽样调查、质量检测等固定试验次数的场景; “先泊松再二项”模型更适合描述稀有事件或随机发生次数的场景, 例如网络流量、顾客到达、罕见疾病病例等。